INSTITUTO ELDORADO
UNIVERSIDADE DE BRASÍLIA – CAMPUS GAMA (FGA)
RESIDÊNCIA EM INTELIGÊNCIA ARTIFICIAL

GRUPO 5 – CHALLENGE 1

CAUAN SOARES
ISABEL AZAR
MARIA GLADYS
MICKEIAS CHARLES

ANÁLISE EXPLORATÓRIA DOS CONJUNTOS DE DADOS PRINCIPAIS PARA O DESENVOLVIMENTO DA FOP – FACT ON PUBLICATION

Brasília – DF
2026

SUMÁRIO

1 INTRODUÇÃO 3
1.1 Objetivos 3
2 METODOLOGIA DA ANÁLISE EXPLORATÓRIA 4
2.1 Conjuntos e partições analisados 4
2.2 Procedimentos comuns 4
2.3 Critérios de tratamento 5
3 AVERITEC-BR 5
3.1 Estrutura e volume 6
3.2 Qualidade dos dados 6
3.3 Distribuição das classes 7
3.4 Características textuais das alegações 8
3.5 Estrutura das evidências 9
3.6 Metadados das alegações 11
3.7 Padrões lexicais e entidades nomeadas 13
4 AVeriTeC ORIGINAL E COMPARAÇÃO COM A VERSÃO TRADUZIDA 14
4.1 Resultados do conjunto original 14
4.2 Comparação entre as versões 14
5 LIAR-BR 15
5.1 Estrutura, volume e qualidade 15
5.2 Anomalias estruturais 16
5.3 Distribuição das classes 17
5.4 Características textuais 18
5.5 Metadados e entidades nomeadas 19
6 SÍNTESE E IMPLICAÇÕES PARA O DESENVOLVIMENTO DA FOP 20
6.1 Quadro comparativo 20
6.2 Implicações para o fluxo de IA 20
6.3 Questões do roteiro ainda não respondidas 22
7 CONSIDERAÇÕES FINAIS 23
REFERÊNCIAS 24
APÊNDICE A – NOTEBOOKS DA ANÁLISE EXPLORATÓRIA 25

1 INTRODUÇÃO

O Challenge 1 da Residência em Inteligência Artificial e Análise de Dados propõe investigar de que maneira sistemas de inteligência artificial podem auxiliar as pessoas a avaliar a confiabilidade de informações sem substituir seu pensamento crítico. A resposta desenvolvida pelo Grupo 5 é a TAKTA, plataforma social de notícias na qual a verificação automatizada ocorre antes da distribuição do conteúdo, por meio do componente denominado FOP – Fact On Publication. A FOP verifica as principais alegações de uma notícia submetida por um veículo verificado, busca evidências externas e classifica cada alegação como suportada, refutada, inconclusiva ou conflitante, declarando a incerteza em vez de tratar a ausência de evidência como falsidade.

O relatório anterior do grupo, dedicado ao levantamento e à avaliação de conjuntos de dados públicos de desinformação, selecionou e hierarquizou os recursos utilizáveis pela FOP. Três deles ocupam posição central no desenho do componente: o AVERITEC-BR, versão em português brasileiro do AVeriTeC e único recurso cujo esquema de rotulagem corresponde integralmente às quatro classes de saída da FOP; o AVeriTeC original, em inglês, que fornece o protocolo de anotação e a referência de comparação; e o LIAR-BR, que associa declarações a metadados do emissor.

O presente relatório documenta a Análise Exploratória de Dados (EDA) realizada sobre esses três conjuntos. Ele descreve sua estrutura, qualidade, distribuição de rótulos, características textuais, evidências e metadados, compara a versão original e a traduzida do AVeriTeC e extrai as implicações dos achados para o desenho do fluxo de IA da FOP, na forma do plano definitivo do fluxo (versão 3). Os requisitos funcionais e não funcionais do componente são tratados em documento próprio.

1.1 Objetivos

O objetivo geral é caracterizar os conjuntos de dados que sustentam o desenvolvimento e a avaliação da FOP. Como objetivos específicos, delimitam-se:

a) descrever a estrutura, o volume e a qualidade das partições analisadas do AVERITEC-BR, do AVeriTeC e do LIAR-BR;

b) caracterizar a distribuição dos rótulos, o comprimento dos textos, os padrões lexicais e os metadados de cada conjunto;

c) analisar a estrutura de evidências em formato de pergunta e resposta do AVeriTeC e de sua versão traduzida;

d) comparar a versão original e a traduzida do AVeriTeC, identificando o que a tradução preservou e o que alterou;

e) derivar da EDA implicações concretas para o fluxo de IA da FOP e registrar as questões que ela ainda não respondeu.

2 METODOLOGIA DA ANÁLISE EXPLORATÓRIA

A análise foi conduzida em três notebooks Jupyter independentes, um por conjunto de dados, executados no ambiente Google Colab. Foram empregadas as bibliotecas pandas e NumPy para manipulação dos dados, Matplotlib e seaborn para visualização, a lista de palavras vazias (stopwords) do NLTK (BIRD; KLEIN; LOPER, 2009) para a análise lexical e o spaCy (HONNIBAL et al., 2020) para o reconhecimento de entidades nomeadas, com os modelos pt_core_news_sm para os textos em português e en_core_web_sm para os textos em inglês.

2.1 Conjuntos e partições analisados

O Quadro 1 resume as partições efetivamente analisadas. No caso do AVeriTeC e do AVERITEC-BR, a análise cobriu as partições de treino e desenvolvimento; a partição de teste, com 1.000 alegações no conjunto original (SCHLICHTKRULL; GUO; VLACHOS, 2023), não integrou a EDA. No caso do LIAR-BR, foram analisadas as três partições distribuídas.

Quadro 1 – Conjuntos e partições analisados na EDA

Conjunto	Idioma	Partições analisadas	Registros	Variáveis	Formato
AVERITEC-BR	Português (tradução automática)	Treino e desenvolvimento	3.068 + 500 = 3.568	14	JSON
AVeriTeC	Inglês	Treino e desenvolvimento	3.068 + 500 = 3.568	14	JSON
LIAR-BR	Português (tradução)	Treino, validação e teste	10.240 + 1.284 + 1.267 = 12.791	14	JSON Lines

Fonte: elaborado pelo grupo (2026).

2.2 Procedimentos comuns

Os três notebooks seguiram uma sequência equivalente de procedimentos, o que permite comparar os resultados entre os conjuntos. A análise começou pela inspeção dos arquivos brutos, antes de qualquer transformação, para identificar estruturas aninhadas e a representação real dos campos. Em seguida, os registros foram convertidos em tabelas e submetidos às seguintes verificações:

a) valores ausentes, considerando não apenas nulos, mas também textos vazios e listas vazias, porque parte das ausências não é reconhecida automaticamente como nula;

b) duplicações completas de registros, repetições textuais do campo principal e sobreposição textual entre partições;

c) distribuição absoluta e relativa dos rótulos por partição;

d) comprimento dos textos em caracteres e palavras, com identificação de valores extremos pelo critério do intervalo interquartil, Q3 + 1,5 × IQR (TUKEY, 1977), e inspeção individual dos casos mais longos;

e) análise lexical de palavras e bigramas após conversão para minúsculas, remoção de URLs, caracteres não alfabéticos e stopwords, com preservação deliberada dos termos de negação (não, nem; no, not, nor);

f) reconhecimento de entidades nomeadas, empregado apenas como exploração;

g) nos conjuntos AVeriTeC, estrutura das evidências em perguntas e respostas e, no AVERITEC-BR, também metadados, meios e domínios das fontes.

2.3 Critérios de tratamento

Nenhum registro foi removido ou imputado automaticamente. Valores extremos, repetições e ausências foram inspecionados e registrados como características dos dados, e os poucos registros problemáticos foram excluídos apenas das análises que dependiam do campo afetado. Essa postura conservadora preserva a possibilidade de tratamento posterior com critérios definidos para cada uso e evita que decisões de limpeza tomadas na exploração contaminem as etapas de preparação e avaliação.

Os resultados do reconhecimento de entidades nomeadas foram tratados como indicadores exploratórios, e não como anotação. Em todos os conjuntos, a inspeção das

entidades mais frequentes revelou erros de categoria e fragmentação, o que tornaria enganosa qualquer leitura quantitativa dessas contagens.

3 AVERITEC-BR

O AVERITEC-BR é o conjunto de maior importância para a FOP: suas quatro classes (Supported, Refuted, Not Enough Evidence e Conflicting Evidence/Cherrypicking) correspondem termo a termo às classes de saída do componente, e cada alegação acompanha evidência estruturada em pergunta e resposta. Segundo o relatório de levantamento do grupo, com base em Delucis et al. (2025), trata-se de tradução automática do AVeriTeC realizada com o modelo Gemma 3.

3.1 Estrutura e volume

Os arquivos analisados somam 3.568 registros, sendo 3.068 de treino e 500 de desenvolvimento. A diferença em relação às 4.568 alegações do AVeriTeC completo corresponde exatamente à partição de teste, que não integrou a análise, e não a perda de registros. Com isso, a EDA confirma um ponto que o plano do fluxo de IA deixava em aberto: os tamanhos das partições de treino e desenvolvimento do AVERITEC-BR coincidem com os do conjunto original.

As duas partições têm as mesmas 14 variáveis, com tipos compatíveis. Os campos centrais são a alegação (claim), o rótulo (label), a justificativa (justification), a data (claim_date), o emissor (speaker), a fonte de publicação (reporting_source), o código de localização (location_ISO_code), os tipos de alegação (claim_types), as estratégias de checagem (fact_checking_strategies), a sinalização de reanotação (required_reannotation) e a estrutura de evidências (questions). Esta última é aninhada, na hierarquia alegação → pergunta → resposta, e foi analisada em tabelas auxiliares para não perder a relação entre alegação e evidência.

3.2 Qualidade dos dados

O Quadro 2 apresenta a proporção de valores ausentes por variável. Os campos essenciais à tarefa de verificação têm completude integral ou quase integral, enquanto as ausências se concentram em metadados e URLs.

Quadro 2 – Valores ausentes por variável no AVERITEC-BR

Variável	Treino (n = 3.068)	Desenvolvimento (n = 500)
claim	1 (0,03%)	0 (0,0%)
label, justification, fact_checking_article, claim_types, fact_checking_strategies, questions	0 (0,0%)	0 (0,0%)
claim_date	105 (3,42%)	0 (0,0%)
location_ISO_code	336 (10,95%)	50 (10,0%)
reporting_source	615 (20,05%)	90 (18,0%)
speaker	695 (22,65%)	118 (23,6%)
original_claim_url	1.611 (52,51%)	238 (47,6%)
cached_original_claim_url	1.923 (62,68%)	242 (48,4%)

Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

O único registro sem texto de alegação (índice 1948 do treino) mantém rótulo, justificativa, metadados e evidências. Por isso, foi preservado nas análises estruturais e excluído apenas das análises textuais.

Não há registros completamente duplicados, mas há repetição textual de alegações. No treino, 139 registros envolvem 50 alegações distintas repetidas, com até sete ocorrências da mesma alegação; no desenvolvimento, 15 registros envolvem 5 alegações. O achado mais relevante é que 16 das 50 alegações repetidas do treino aparecem com dois rótulos diferentes, em alguns casos associadas ao mesmo artigo de checagem. Além disso, 7 alegações textualmente idênticas estão presentes simultaneamente no treino e no desenvolvimento, por vezes com rótulos distintos. Essas repetições foram preservadas, pois diferenças de data, emissor e contexto podem justificá-las, mas indicam que o texto da alegação, isoladamente, não carrega toda a informação usada na verificação.

A variável required_reannotation sinaliza 862 registros do treino (28,1%) e 122 do desenvolvimento (24,4%). A sinalização não se distribui uniformemente entre as classes, como mostra o Quadro 3: ela é mais frequente justamente nas classes minoritárias, que são também as mais relevantes para a FOP. O campo não informa o motivo da sinalização, de modo que a associação observada é descritiva e não causal.

Quadro 3 – Proporção de registros sinalizados para reanotação, por classe

Classe	Treino	Desenvolvimento
Conflicting Evidence/Cherrypicking	48,72%	44,74%
Not Enough Evidence	35,46%	34,29%
Supported	27,33%	18,85%
Refuted	24,97%	22,95%

Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

3.3 Distribuição das classes

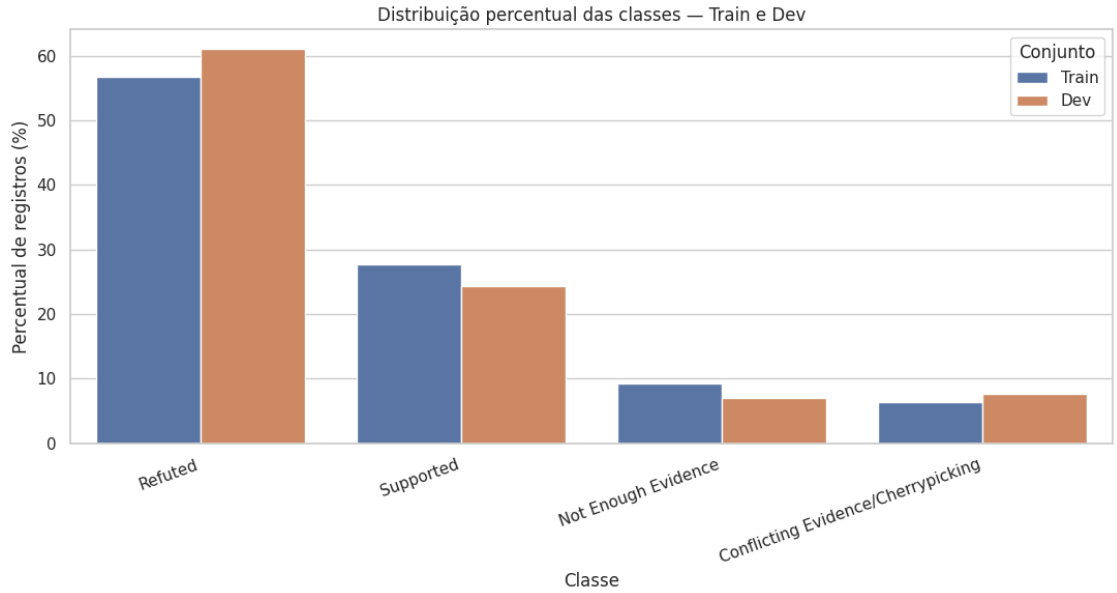
A distribuição dos rótulos é desbalanceada, conforme o Quadro 4 e a Figura 1. A classe Refuted concentra mais da metade dos registros nas duas partições, Supported representa cerca de um quarto, e as classes Not Enough Evidence e Conflicting Evidence/Cherrypicking somam menos de 16% do treino. Entre as partições, a composição é semelhante; a principal variação ocorre nas classes minoritárias.

Quadro 4 – Distribuição das classes no AVERITEC-BR

Classe	Treino	Desenvolvimento
Refuted	1.742 (56,78%)	305 (61,0%)
Supported	849 (27,67%)	122 (24,4%)
Not Enough Evidence	282 (9,19%)	35 (7,0%)
Conflicting Evidence/Cherrypicking	195 (6,36%)	38 (7,6%)

Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

Figura 1 – Distribuição percentual das classes no treino e no desenvolvimento do AVERITEC-BR



Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

Esse desbalanceamento tem duas consequências para a FOP. A primeira, já prevista no protocolo de avaliação, é que métricas globais escondem o desempenho nas classes minoritárias, e por isso o desempenho deve ser reportado por classe. A segunda é que o desenvolvimento contém apenas 35 alegações Not Enough Evidence e 38 Conflicting Evidence/Cherrypicking, números que produzirão intervalos de confiança largos para as métricas dessas classes.

3.4 Características textuais das alegações

As alegações são curtas. No treino, têm em média 114,28 caracteres e 18,81 palavras, com mediana de 17 palavras e metade dos textos entre 13 e 23 palavras; no desenvolvimento, a média é de 19,34 palavras e a mediana de 18. Pelo critério do IQR, o limite superior é de 38 palavras, e 113 alegações do treino (3,68%) o ultrapassam. A inspeção das dez mais longas mostrou citações extensas, declarações compostas e alegações com mais contexto, sem sinais de concatenação indevida de registros, razão pela qual foram mantidas.

Entre as 113 alegações extremas, 40,71% estão sinalizadas para reanotação, contra 28,1% no treino completo. A associação é descritiva: o comprimento médio dos registros sinalizados (19,56 palavras) é pouco superior ao dos não sinalizados (18,52), de modo que o comprimento, sozinho, não separa os dois grupos.

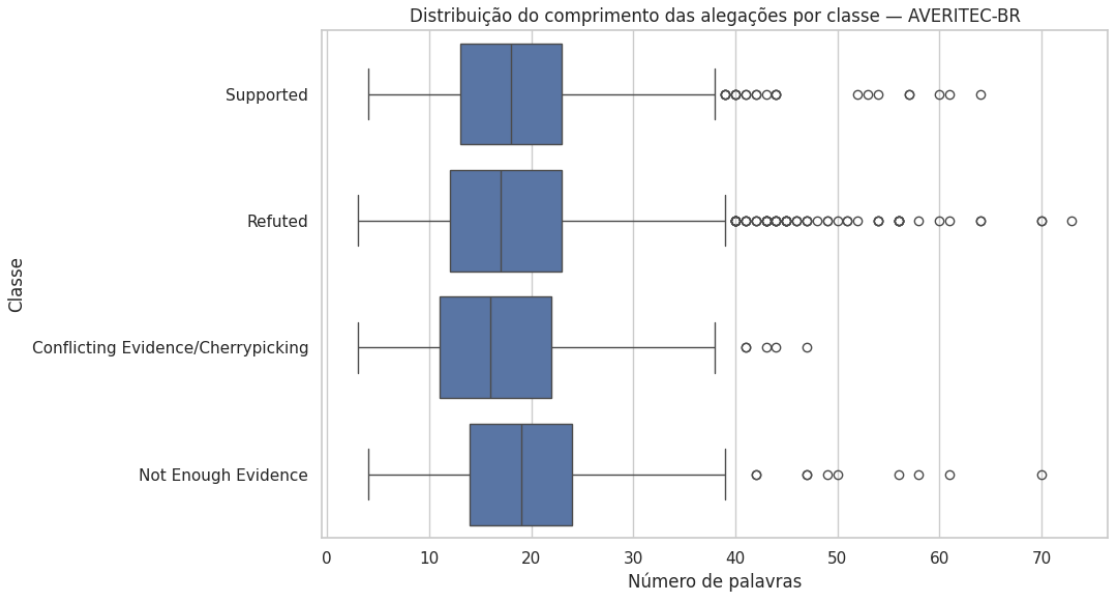
O Quadro 5 e a Figura 2 comparam o comprimento por classe. As medianas variam de 16 a 19 palavras e as distribuições se sobrepõem fortemente, o que indica que o comprimento, isoladamente, não separa as classes de forma evidente. A inspeção visual não substitui, porém, o teste quantitativo de atalho previsto no roteiro da EDA, discutido na seção 6.3.

Quadro 5 – Comprimento das alegações, em palavras, por classe (treino)

Classe	**n**	**Média**	**Mediana**	**Desvio-padrão**	**Mín.–Máx.**
Conflicting Evidence/Cherrypicking	195	17,75	16	8,48	3–47
Refuted	1.742	18,60	17	9,37	3–73
Supported	848	19,07	18	8,37	4–64
Not Enough Evidence	282	20,06	19	9,70	4–70

Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

Figura 2 – Distribuição do comprimento das alegações por classe no AVERITEC-BR



Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

3.5 Estrutura das evidências

Todas as alegações têm ao menos uma pergunta e uma resposta. No treino, cada alegação tem em média 2,60 perguntas e 2,76 respostas, com mediana de 2 e máximo de 16; no desenvolvimento, as médias são 2,57 e 2,80. Nas duas partições somadas há 9.272 perguntas, das quais 8.734 têm exatamente uma resposta, 472 têm duas, 64 têm três e 2 têm quatro.

As 9.878 respostas dividem-se em quatro tipos: Extractive, com 5.278 (53,43%); Abstractive, com 2.586 (26,18%); Boolean, com 1.589 (16,09%); e Unanswerable, com 425 (4,30%). A completude dos campos das respostas depende do tipo, e a maior parte das ausências é esperada: boolean_explanation só é preenchido em respostas Boolean, e as respostas Unanswerable não têm fonte. Foram encontradas apenas duas ausências inesperadas, ambas no treino: uma resposta Extractive sem texto e uma resposta Boolean sem URL e meio de fonte.

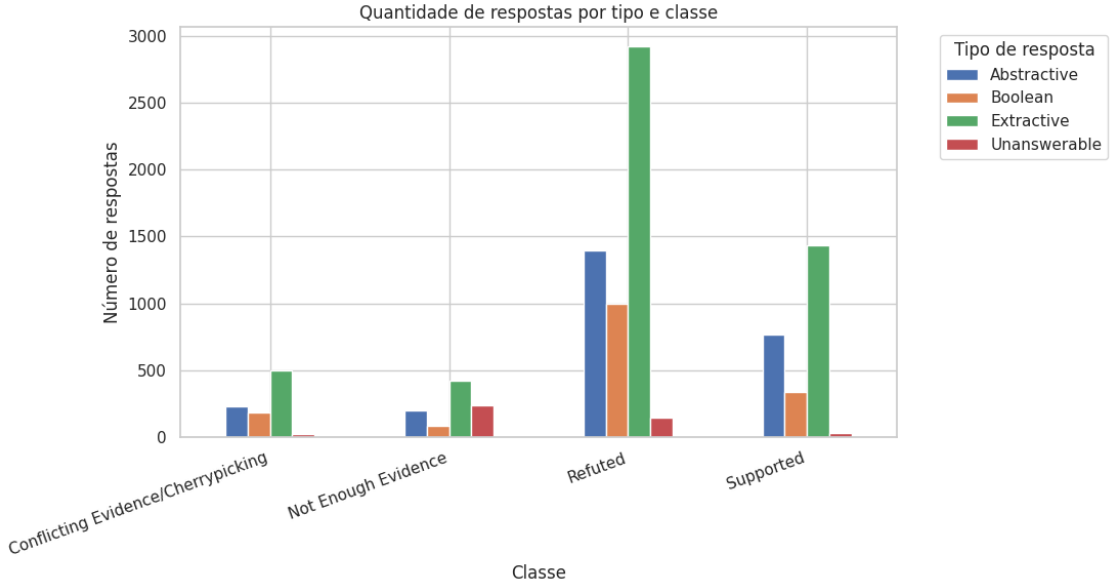
A composição das evidências varia entre as classes, como mostram o Quadro 6 e a Figura 3. A classe Conflicting Evidence/Cherrypicking tem a estrutura mais extensa, com média de 3,60 perguntas e 3,97 respostas por alegação. A diferença mais marcante, porém, está na classe Not Enough Evidence: 24,89% de suas respostas são Unanswerable, contra no máximo 2,66% nas demais classes.

Quadro 6 – Estrutura das evidências por classe (treino e desenvolvimento)

Classe	Alegações	Perguntas (média)	Respostas (média)	Unanswerable (% das respostas)
Conflicting Evidence/Cherrypicking	233	3,60	3,97	2,16%
Not Enough Evidence	317	2,80	2,95	24,89%
Refuted	2.047	2,51	2,67	2,66%
Supported	971	2,49	2,64	1,05%

Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

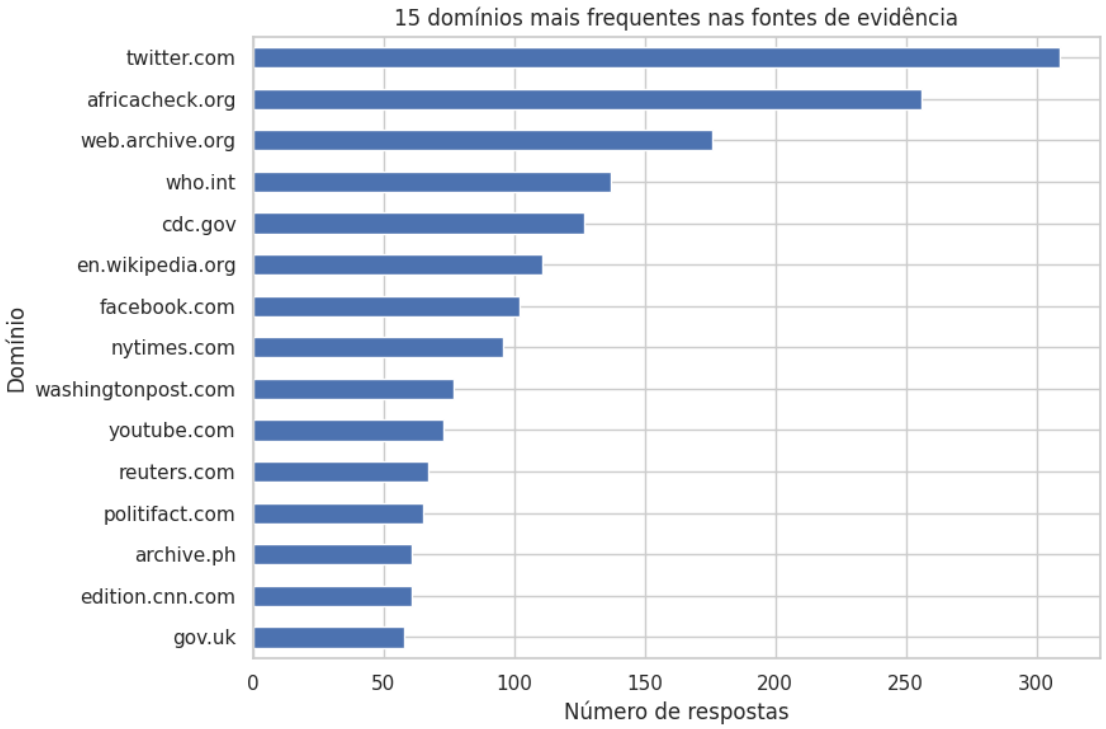
Figura 3 – Quantidade de respostas por tipo e por classe no AVERITEC-BR



Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

Quanto ao meio das fontes, predominam textos da web (72,38% das respostas com fonte), seguidos de PDF (11,76%), metadados (6,34%) e tabelas da web (4,47%); imagens, vídeos e áudio têm participação residual. Quanto à origem, 3.526 URLs apontavam inicialmente para web.archive.org. Como essas URLs preservam o endereço da página arquivada, o domínio original foi recuperado, e o número de domínios distintos passou de 1.879 para 2.453. Após a recuperação, os domínios mais frequentes são twitter.com (309), africacheck.org (256), who.int (137), cdc.gov (127) e en.wikipedia.org (111), conforme a Figura 4. Permaneceram 176 ocorrências de web.archive.org cujo domínio original não foi recuperado pela regra utilizada.

Figura 4 – Domínios mais frequentes nas fontes de evidência do AVERITEC-BR, após recuperação das URLs arquivadas



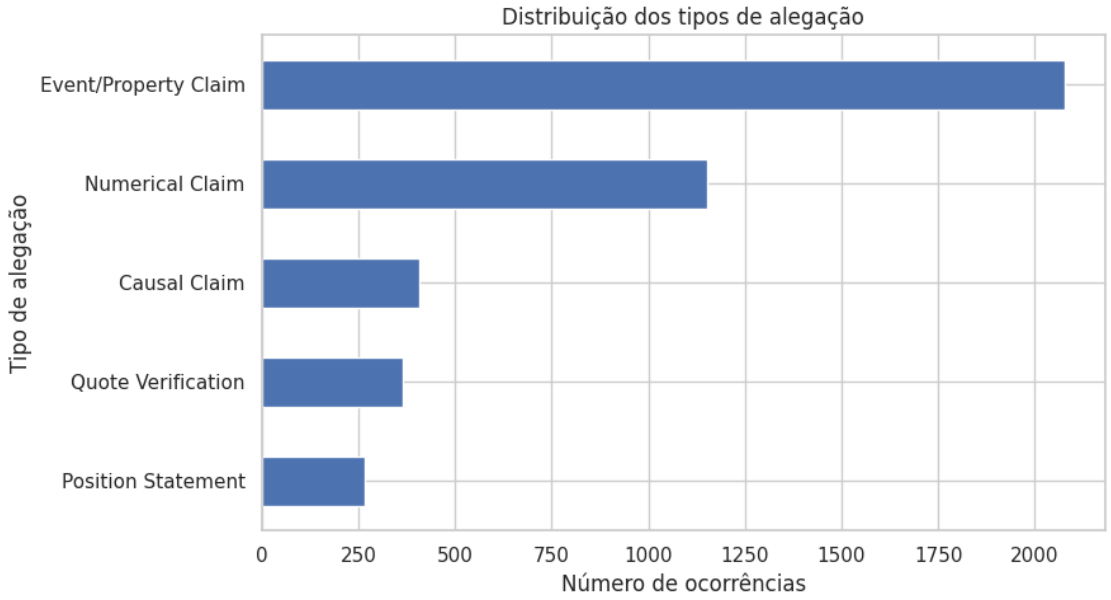
Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

Dois domínios de agências de checagem, africacheck.org (256) e politifact.com (65), aparecem entre os mais frequentes das evidências-ouro. Esse achado é retomado na seção 6.2, porque confirma empiricamente o risco de vazamento que motivou o protocolo de avaliação do fluxo.

3.6 Metadados das alegações

O campo claim_types é multirrótulo e soma 4.271 ocorrências em cinco categorias: Event/Property Claim (2.079; 48,68%), Numerical Claim (1.154; 27,02%), Causal Claim (9,53%), Quote Verification (8,52%) e Position Statement (6,25%), conforme a Figura 5. A maioria das alegações (80,80%) recebe um único tipo. Admitindo que uma categoria não se repete na mesma alegação, cerca de um terço das alegações (1.154 de 3.568) é numérica.

Figura 5 – Distribuição dos tipos de alegação no AVERITEC-BR



Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

As estratégias de checagem somam 5.303 ocorrências, com predomínio de Written Evidence (53,97%), seguida de Consultation (19,74%) e Numerical Comparison (19,52%). Diferentemente dos tipos de alegação, a combinação de estratégias é frequente: 42,91% das alegações usam mais de uma.

Das 3.568 alegações, 3.182 têm localização informada, distribuída em 70 códigos de país. A distribuição é concentrada, como mostra a Figura 6: Estados Unidos (1.461), Índia (404), Reino Unido (259), Nigéria (247), Quênia (233) e África do Sul (162). O Brasil não figura entre as 20 localidades mais frequentes.

Figura 6 – Localizações mais frequentes das alegações do AVERITEC-BR



Fonte: elaborado pelo grupo a partir do notebook EDA_AVERITEC_BR (2026).

O campo speaker está preenchido em 2.755 registros, com 1.536 valores distintos, liderados por Donald Trump (223). A grafia não é padronizada: a mesma pessoa aparece como Donald Trump, US President Donald Trump e Donald trump, e o campo inclui categorias genéricas como Social Media Users. A normalização conservadora de maiúsculas e espaços reduziu os valores distintos apenas para 1.519, porque diferenças de cargo e título não foram agrupadas automaticamente. O campo reporting_source, preenchido em 2.863 registros, tem comportamento semelhante: após a mesma normalização, passa de 678 para 609 valores, com predomínio de facebook (987), twitter (403) e youtube (86), e mistura plataformas, veículos e descrições de contexto, como discursos e coletivas de imprensa.

3.7 Padrões lexicais e entidades nomeadas

Após a preparação textual, a palavra mais frequente é não (461 ocorrências), resultado da preservação deliberada das negações. Seguem-se termos geográficos, políticos e de saúde, como eua, covid, trump, presidente, coronavírus, governo e nigéria. Os bigramas mais frequentes, como donald trump (170), estados unidos (117), áfrica sul (93), joe biden (82) e reino unido (81), confirmam o predomínio de política, saúde pública e localidades.

O reconhecimento de entidades identificou 6.746 ocorrências, com 2.628 formas distintas, nas categorias LOC (3.445), PER (1.560), ORG (881) e MISC (860). A inspeção mostrou erros recorrentes: COVID-19, Trump, Biden, US$ e Congresso classificados como localidade, e a mesma pessoa fragmentada em formas como Donald Trump, Presidente Trump e Presidente Donald Trump. Esse resultado é relevante também para o passo 2 do fluxo, que depende de NER para descontextualizar alegações, como discutido na seção 6.2.

4 AVeriTeC ORIGINAL E COMPARAÇÃO COM A VERSÃO TRADUZIDA

A EDA do AVeriTeC original teve dois propósitos: caracterizar o conjunto em sua língua de origem e verificar o que a tradução preservou. Como as estruturas são equivalentes, a análise do original privilegiou os pontos em que as versões podem divergir, evitando repetir explorações estruturais já feitas no AVERITEC-BR.

4.1 Resultados do conjunto original

O original tem as mesmas 3.568 alegações (3.068 de treino e 500 de desenvolvimento), as mesmas 14 variáveis e o mesmo padrão de ausências, inclusive o registro sem alegação no índice 1948. As alegações em inglês têm em média 103,40 caracteres e 17,04 palavras no treino, com mediana de 15 palavras. Pelo critério do IQR, o limite superior é de 36 palavras, e 96 alegações (3,13%) o ultrapassam; a inspeção mostrou citações e declarações compostas legítimas.

Não há duplicações completas, mas 109 registros do treino (3,55%) envolvem 40 alegações repetidas, e 15 registros do desenvolvimento (3,00%) envolvem 6. Quatro alegações idênticas estão no treino e no desenvolvimento. A estrutura de evidências e a distribuição dos tipos de resposta são idênticas às da versão traduzida. A análise lexical confirma os mesmos temas, com covid, president, trump e people entre as palavras mais frequentes e donald trump, south africa e united states entre os bigramas. O NER identificou 7.979 ocorrências de entidades, com 3.243 formas distintas, e apresentou erros análogos, como Burisma classificada como entidade geopolítica.

4.2 Comparação entre as versões

O Quadro 7 reúne os indicadores das duas versões. A tradução preservou integralmente a estrutura, os rótulos e as evidências, mas alterou o texto de formas que importam para a FOP.

Quadro 7 – Comparação entre o AVeriTeC original e o AVERITEC-BR (treino, salvo indicação)

Indicador	**AVeriTeC (inglês)**	**AVERITEC-BR (português)**
Registros (treino + desenvolvimento)	3.068 + 500	3.068 + 500
Distribuição de rótulos	Idêntica	Idêntica
Padrão de ausências	Idêntico	Idêntico
Perguntas e respostas por alegação (média)	2,60 e 2,76	2,60 e 2,76
Tipos de resposta (9.878 respostas)	Idênticos	Idênticos
Palavras por alegação (média / mediana)	17,04 / 15	18,81 / 17
Limite IQR e alegações extremas	36 palavras; 96 (3,13%)	38 palavras; 113 (3,68%)
Alegações distintas repetidas no treino	40 (109 registros)	50 (139 registros)
Alegações repetidas no desenvolvimento	6 (15 registros)	5 (15 registros)
Alegações idênticas em treino e desenvolvimento	4	7

Fonte: elaborado pelo grupo a partir dos notebooks EDA_AVeriTeC e EDA_AVERITEC_BR (2026).

Três diferenças merecem registro. A primeira é o alongamento de cerca de 10% no número médio de palavras, efeito esperado da tradução para o português e relevante para o limite de tokens dos modelos do fluxo. A segunda é o aumento das repetições textuais no treino (de 40 para 50 alegações distintas) e da sobreposição entre partições (de 4 para 7). Como os registros são os mesmos, a hipótese mais provável é que a tradução tenha tornado idênticas alegações que eram distintas no original. A hipótese ainda precisa ser confirmada pelo pareamento dos registros, mas, se confirmada, a tradução cria sobreposições que não existiam no conjunto original.

A terceira diferença é qualitativa e foi observada no primeiro registro do treino, exibido em ambos os notebooks. A justificativa original, “No former experience stated.”, foi traduzida como “Experiência anterior mencionada.”, o que inverte o sentido da afirmação. Um único exemplo não permite estimar a frequência desse tipo de erro, mas mostra que a tradução automática pode alterar o conteúdo semântico, e não apenas a forma. Isso reforça a necessidade da inspeção de qualidade da tradução prevista no roteiro da EDA e ainda não realizada.

5 LIAR-BR

O LIAR-BR é a versão em português do LIAR (WANG, 2017) e reúne declarações curtas de figuras públicas norte-americanas, rotuladas em uma escala de seis pontos, com metadados do emissor e contagens históricas de seus rótulos anteriores. No relatório de

levantamento, o conjunto foi posicionado como apoio à camada de avaliação do emissor, e não como base de avaliação do veredito, porque não fornece evidência.

5.1 Estrutura, volume e qualidade

Os arquivos analisados têm 12.791 registros e 14 variáveis: 10.240 no treino, 1.284 na validação e 1.267 no teste. O total é inferior às 12.836 declarações registradas no levantamento do grupo. No LIAR original, as partições têm 10.269, 1.284 e 1.283 declarações (WANG, 2017); a diferença está, portanto, no treino (29 a menos) e no teste (16 a menos). A seção 5.2 apresenta uma explicação provável.

As variáveis incluem o identificador (statement_ID), o rótulo (label), a declaração (statement), os assuntos (subjects), o emissor (speaker), seu cargo (speaker_job_title), o estado (state_info), a filiação partidária (party_affiliation), o contexto (context) e cinco contagens históricas de rótulos do emissor (hist_*_counts). As ausências estão codificadas como textos vazios, e não como nulos, e por isso não são detectadas pelos métodos usuais. O Quadro 8 resume os casos encontrados.

Quadro 8 – Valores ausentes no treino do LIAR-BR (n = 10.240)

Variável	Ausentes	Percentual
speaker_job_title	2.897	28,29%
state_info	2.207	21,55%
context	102	1,00%
speaker, party_affiliation, subjects	2 cada	0,02%
statement, label, statement_ID, hist_*_counts	0	0,00%

Fonte: elaborado pelo grupo a partir do notebook EDA_LIAR (2026).

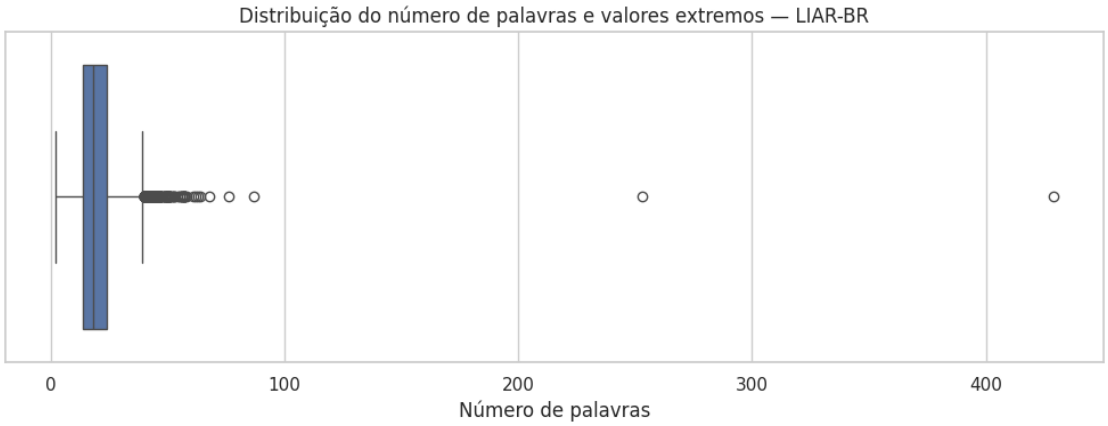
Não há registros nem identificadores duplicados, mas há 12 pares de declarações textualmente idênticas no treino, algumas com rótulos diferentes. A declaração sobre Phoenix ser a segunda capital mundial de sequestros, por exemplo, aparece com os rótulos false e pants-fire. Entre partições, não há identificadores compartilhados, mas 4 declarações se repetem entre treino e validação e 2 entre treino e teste, todas com o mesmo rótulo.

5.2 Anomalias estruturais

A distribuição do comprimento tem cauda longa à direita: a mediana é de 18 palavras, mas a declaração mais longa tem 429 palavras e 2.724 caracteres. Pelo critério do IQR, o limite é de 39 palavras, e 228 registros (2,23%) o ultrapassam, conforme a Figura 7. A inspeção dos

casos mais extremos revelou um problema que não é de conteúdo, e sim de formatação: em quatro registros (0,0391% do treino), o campo statement contém, separados por tabulações, valores de outras variáveis e identificadores de outros registros, seguidos de outras declarações. Dois desses registros correspondem às declarações de 429 e 253 palavras.

Figura 7 – Distribuição do número de palavras e valores extremos no treino do LIAR-BR



Fonte: elaborado pelo grupo a partir do notebook EDA_LIAR (2026).

O padrão é típico de falha de leitura do arquivo, em que linhas de registros distintos foram fundidas em um único campo. Uma hipótese coerente com esse padrão, a ser confirmada, é que os registros absorvidos dessa forma expliquem parte da diferença entre o total analisado e o total do LIAR original. De todo modo, os quatro registros precisam ser corrigidos ou descartados antes de qualquer uso do conjunto.

5.3 Distribuição das classes

As seis classes são mais equilibradas do que no AVeriTeC, como mostram o Quadro 9 e a Figura 8. Cinco classes têm entre 16% e 21% do treino, e apenas pants-fire é minoritária, com 8,19%. A composição é semelhante nas três partições; as maiores diferenças estão na validação, com mais barely-true (18,46%) e menos true (13,16%).

Quadro 9 – Distribuição das classes no LIAR-BR

Classe	Treino	Validação	Teste
pants-fire	839 (8,19%)	9,03%	7,26%
false	1.995 (19,48%)	20,48%	19,65%
barely-true	1.654 (16,15%)	18,46%	16,73%
half-true	2.114 (20,64%)	19,31%	20,92%
mostly-true	1.962 (19,16%)	19,55%	19,02%
true	1.676 (16,37%)	13,16%	16,42%

Fonte: elaborado pelo grupo a partir do notebook EDA_LIAR (2026).

Figura 8 – Distribuição das classes no treino, na validação e no teste do LIAR-BR

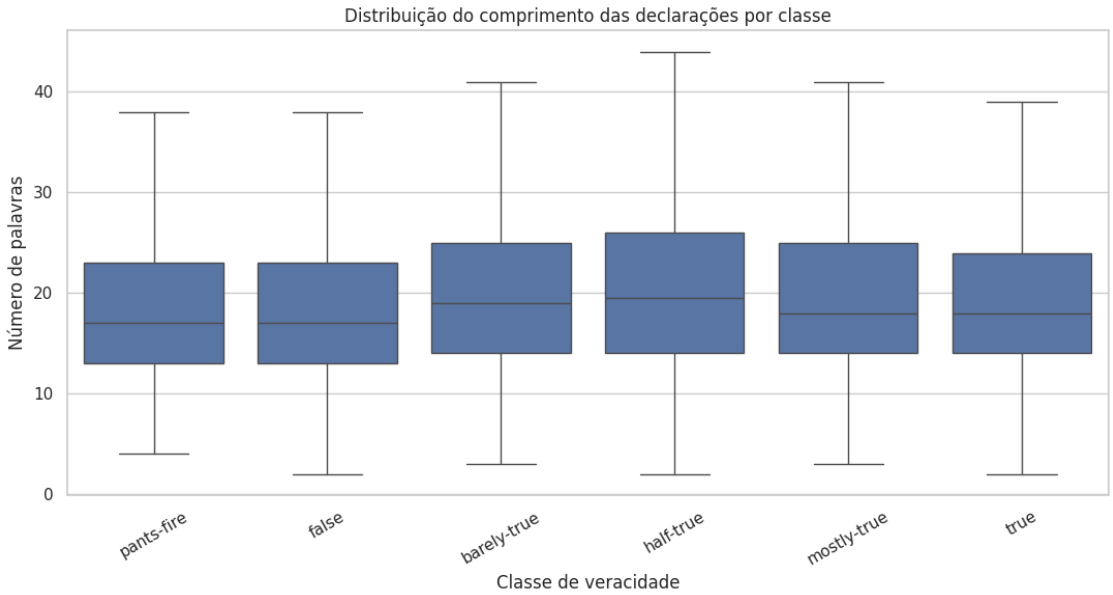


Fonte: elaborado pelo grupo a partir do notebook EDA_LIAR (2026).

5.4 Características textuais

Excluídos os quatro registros anômalos, as medianas de comprimento por classe variam de 17 a 19,5 palavras, e as médias de 18,42 (false) a 20,62 (half-true), com desvios-padrão semelhantes. A Figura 9 mostra a forte sobreposição das distribuições: o comprimento, isoladamente, não distingue visualmente as classes.

Figura 9 – Distribuição do comprimento das declarações por classe no LIAR-BR



Fonte: elaborado pelo grupo a partir do notebook EDA_LIAR (2026).

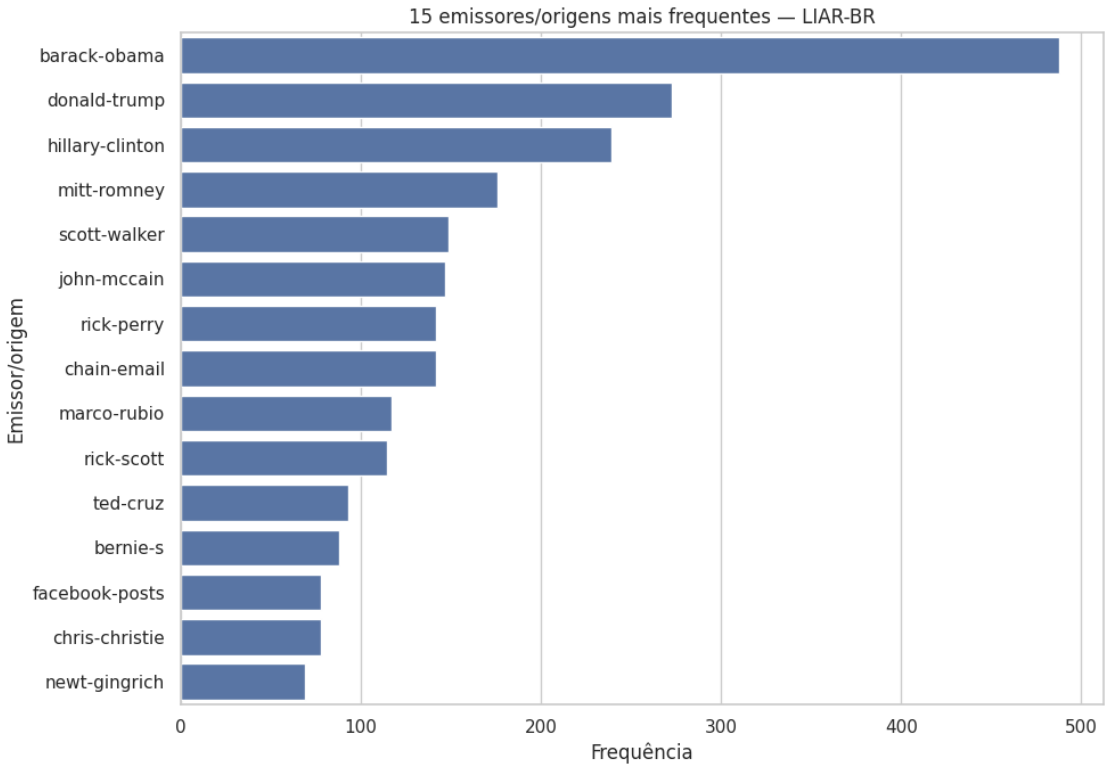
Na análise lexical, não é a palavra mais frequente, com 1.672 ocorrências, seguida de termos políticos e econômicos como obama, lei, saúde, impostos, presidente e empregos. Os bigramas mais frequentes são estados unidos (453), barack obama (354), hillary clinton (196) e projeto lei (182). Os termos de negação nunca, nada, ninguém, nenhum e nenhuma não integram a lista de stopwords do NLTK e foram mantidos naturalmente.

5.5 Metadados e entidades nomeadas

O campo subjects apresentava a mesma categoria com grafias diferentes, como economia e Economia. Após a padronização para minúsculas, os assuntos mais frequentes são economia (1.162), impostos (994), orçamento federal (731), educação (724) e cuidados de saúde (701). Como uma declaração pode ter vários assuntos, essas frequências não são mutuamente exclusivas.

No campo speaker, os emissores mais frequentes são barack-obama (488), donald-trump (273), hillary-clinton (239) e mitt-romney (176), conforme a Figura 10. O campo, porém, não contém apenas pessoas: chain-email (142), facebook-posts (78) e blog-posting (59) figuram entre os valores mais comuns, e há formas truncadas, como bernie-s.

Figura 10 – Emissores e origens mais frequentes das declarações no LIAR-BR



Fonte: elaborado pelo grupo a partir do notebook EDA_LIAR (2026).

O NER identificou ocorrências de LOC (6.397), PER (4.391), ORG (1.891) e MISC (1.676). As pessoas foram, em geral, bem reconhecidas, mas obama, us$ e congresso aparecem entre as localidades, e us$, senado e presidente entre as entidades diversas. Os erros são coerentes com os observados no AVERITEC-BR e confirmam a limitação do modelo pt_core_news_sm em textos traduzidos sobre contexto político estrangeiro.

6 SÍNTESE E IMPLICAÇÕES PARA O DESENVOLVIMENTO DA FOP

6.1 Quadro comparativo

O Quadro 10 reúne os principais indicadores dos três conjuntos.

Quadro 10 – Síntese comparativa dos conjuntos analisados

Indicador	AVERITEC-BR	AVeriTeC	LIAR-BR
Registros analisados	3.568	3.568	12.791
Classes	4 (correspondência integral com a FOP)	4	6 (escala de veracidade)
Classe majoritária no treino	Refuted (56,78%)	Refuted (56,78%)	half-true (20,64%)
Classe minoritária no treino	Conflicting (6,36%)	Conflicting (6,36%)	pants-fire (8,19%)
Evidência estruturada	Sim (pergunta e resposta)	Sim (pergunta e resposta)	Não
Mediana de palavras (treino)	17	15	18
Textos idênticos com rótulos diferentes	16 alegações no treino	Não medido	Presentes em pares repetidos
Sobreposição textual entre partições	7 alegações	4 alegações	6 declarações
Principal problema de qualidade	Rótulos divergentes; reanotação em 28,1%	Repetições textuais	4 registros com falha de leitura
Contexto geográfico	Majoritariamente EUA, Índia, Reino Unido e África	Idem	EUA

Fonte: elaborado pelo grupo (2026).

6.2 Implicações para o fluxo de IA

As implicações a seguir relacionam os achados da EDA ao plano definitivo do fluxo de IA da FOP (versão 3). Algumas confirmam decisões já tomadas; outras exigem ajustes na preparação dos dados.

a) Divisão dos dados por grupos de alegações idênticas. O plano divide o treino do AVERITEC-BR em duas partes, uma para ajustar limiares e outra para calibrar. Como 50 alegações se repetem no treino e 16 delas têm rótulos divergentes, uma divisão aleatória por registro colocaria a mesma alegação nas duas partes. A divisão deve, portanto, agrupar alegações textualmente idênticas, e as 7 alegações compartilhadas entre treino e desenvolvimento devem ser tratadas antes de o desenvolvimento ser usado para comparar variantes.

b) Confirmação empírica do risco de vazamento. A presença de africacheck.org e politifact.com entre os domínios mais frequentes das evidências-ouro confirma que parte da evidência vem de agências de checagem. Isso sustenta o protocolo anti-vazamento do plano, que exclui domínios de agências da base de evidência na avaliação. A EDA não verificou se o knowledge store traz data de publicação por documento, condição necessária para o filtro temporal.

c) Taxa-base desfavorável à precisão de refutada. Com Refuted em 57% a 61% dos registros, a precisão de refutada medida no AVERITEC-BR será favorecida por uma taxa-base que não se espera encontrar em notícias de veículos verificados. A EDA confirma, assim, a premissa da seção de validade externa do plano: o desempenho medido no teste não estima o de produção, e o conjunto de produção previsto como portão do piloto é indispensável.

d) Classes minoritárias pequenas e menos estáveis. As classes Not Enough Evidence e Conflicting Evidence/Cherrypicking são as menos numerosas e as mais sinalizadas para reanotação (até 48,72%). Suas métricas terão intervalos largos, e seus rótulos são menos estáveis. Isso reforça a calibração por classe prevista no plano e recomenda cautela na escolha entre calibrador por classe e calibrador único com a classe como variável.

e) Associação entre respostas Unanswerable e a classe Not Enough Evidence. Um quarto das respostas dessa classe é Unanswerable, contra no máximo 2,66% nas demais. A associação é esperada pelo próprio desenho da anotação, mas pode funcionar como atalho: um modelo que receba as respostas-ouro pode aprender a prever a classe pela presença de Unanswerable. Em produção, esse sinal não existe, porque a FOP recupera trechos, não respostas anotadas. O teste quantitativo desse atalho continua pendente.

f) Prioridade do verificador numérico. Cerca de um terço das alegações é do tipo Numerical Claim, e Numerical Comparison responde por 19,52% das estratégias de checagem.

O plano condiciona o verificador numérico a uma medida dessa proporção; a EDA a fornece e indica que o componente é prioritário entre os incrementos.

g) Fragilidade do NER para a descontextualização. O passo 2 do fluxo usa NER para substituir pronomes e identificar a atribuição de declarações. Os erros observados, como pessoas classificadas como localidade e a mesma pessoa em formas diferentes, afetam diretamente essa etapa. O modelo pt_core_news_sm é o menor da família; o plano prevê o pt_core_news_lg e, como alternativa, um BERTimbau ajustado para NER. A escolha deve ser feita com medida em notícias brasileiras, e não com base nos resultados desta EDA, obtidos em textos traduzidos.

h) Distância entre o conteúdo dos dados e o da TAKTA. Nenhum dos conjuntos trata do contexto brasileiro: o AVERITEC-BR concentra-se em Estados Unidos, Índia, Reino Unido e países africanos, e o LIAR-BR na política norte-americana. Isso reforça a validade externa limitada dos resultados e a necessidade de avaliar a FOP em alegações originalmente brasileiras.

i) Papel restrito do LIAR-BR. A heterogeneidade do campo speaker, que mistura pessoas e origens como chain-email, a escala de seis pontos sem mapeamento direto para as quatro classes da FOP e a ausência de evidência confirmam que o conjunto não serve para avaliar o veredito. Caso seja usado na camada de avaliação de fonte, as contagens históricas do emissor devem ser verificadas antes, para confirmar que não incluem o rótulo da própria declaração, o que configuraria vazamento do rótulo.

6.3 Questões do roteiro ainda não respondidas

O roteiro da EDA definia perguntas orientadas aos níveis de implementação da FOP. A análise realizada é predominantemente descritiva e responde a parte delas. O Quadro 11 registra as questões pendentes, para que sejam incorporadas às próximas iterações.

Quadro 11 – Questões do roteiro da EDA pendentes

Questão	**Situação**	**Próximo passo**
Os atributos superficiais (comprimento, fonte, metadados) predizem o rótulo?	Respondida apenas visualmente para o comprimento	Medir a AUC ou o macro-F1 de classificadores com um único atributo
O campo justification vaza o veredito?	Não analisada	Treinar classificador apenas sobre a justificativa
A proporção de Unanswerable prevê Not Enough Evidence?	Associação descrita (24,89%)	Medir o atalho quantitativamente

Questão	Situação	Próximo passo
Qual é a qualidade da tradução do AVERITEC-BR?	Um erro de inversão de sentido observado	Parear registros, comparar números e nomes, inspecionar amostra
As repetições adicionais do AVERITEC-BR vêm da tradução?	Hipótese	Parear registros com o original
Qual fração das alegações excede o limite de tokens dos modelos?	Não analisada	Tokenizar com o tokenizador do modelo NLI escolhido
O knowledge store tem data por documento e cobre a evidência-ouro?	Não analisado	Analisar amostra do knowledge store
Qual regra converte pergunta e resposta em pares NLI?	Não analisada	Propor e comparar regras de conversão
Qual é o tamanho e a disponibilidade de rótulos do teste do AVERITEC-BR?	Não analisado	Inspecionar a partição de teste

Fonte: elaborado pelo grupo (2026).

7 CONSIDERAÇÕES FINAIS

A análise exploratória permite três conclusões de consequência imediata para o projeto.

A primeira é que o AVERITEC-BR se confirma como base adequada ao desenvolvimento da FOP, mas com ressalvas que precisam ser tratadas antes da avaliação. A tradução preservou integralmente a estrutura, os rótulos e as evidências do AVeriTeC, e as partições de treino e desenvolvimento têm os tamanhos do conjunto original. Em contrapartida, o conjunto traz alegações idênticas com rótulos diferentes, sobreposição entre partições, sinalização de reanotação concentrada nas classes minoritárias e ao menos um erro de tradução que inverte o sentido de uma justificativa. Os dois primeiros problemas exigem uma divisão dos dados por grupos de alegações; o último exige a inspeção de qualidade da tradução ainda pendente.

A segunda é que os dados confirmam empiricamente decisões do plano do fluxo de IA tomadas antes da EDA. A presença de agências de checagem entre as fontes das evidências-ouro sustenta o protocolo anti-vazamento; a predominância de Refuted sustenta a advertência de que a precisão medida no teste não estima a de produção; a proporção de alegações numéricas justifica priorizar o verificador numérico; e os erros de reconhecimento de entidades mostram que a descontextualização por regras precisa ser medida em textos brasileiros. O LIAR-BR, por sua vez, confirma seu papel restrito: sem evidência, com escala de seis pontos e com metadados heterogêneos, não serve para avaliar o veredito.

A terceira é que a EDA realizada é predominantemente descritiva e deixa em aberto as perguntas quantitativas do roteiro, reunidas no Quadro 11. Elas são o próximo passo natural:

sem os testes de atalho e de vazamento e sem a inspeção da qualidade da tradução, os limiares e o calibrador do fluxo seriam ajustados sobre dados cujas armadilhas ainda não foram medidas.

REFERÊNCIAS

BIRD, Steven; KLEIN, Ewan; LOPER, Edward. **Natural language processing with Python**. Sebastopol: O'Reilly Media, 2009.

DELUCIS, Marcelo Mussi; FRAGA, Lucas; PARRAGA, Otávio; OLIVEIRA, Christian Mattjie de; RAVAZIO, Rafaela Cappelari; BARROS, Rodrigo C.; KUPSSINSKÜ, Lucas S. Automated fact-checking in Brazilian Portuguese: resources and baselines. In: SIMPÓSIO BRASILEIRO DE TECNOLOGIA DA INFORMAÇÃO E DA LINGUAGEM HUMANA (STIL), 2025. **Anais** [...]. Porto Alegre: SBC, 2025. DOI: 10.5753/stil.2025.37820.

GRUPO 5. **Fluxo de IA da FOP**: versão 3 (plano definitivo). Brasília: Residência em Inteligência Artificial, Instituto Eldorado; UnB – Campus Gama, 2026. Documento interno.

GRUPO 5. **Levantamento e avaliação de conjuntos de dados públicos de desinformação para o treinamento e a avaliação da FOP – Fact On Publication**. Brasília: Residência em Inteligência Artificial, Instituto Eldorado; UnB – Campus Gama, 2026. Relatório técnico.

GRUPO 5. **Roteiro da FOP para a análise exploratória de dados**. Brasília: Residência em Inteligência Artificial, Instituto Eldorado; UnB – Campus Gama, 2026. Documento interno.

HONNIBAL, Matthew; MONTANI, Ines; VAN LANDEGHEM, Sofie; BOYD, Adriane. **spaCy**: industrial-strength natural language processing in Python. [S. l.]: Zenodo, 2020. DOI: 10.5281/zenodo.1212303.

SCHLICHTKRULL, Michael; GUO, Zhijiang; VLACHOS, Andreas. AVeriTeC: a dataset for real-world claim verification with evidence from the web. In: CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS) – DATASETS AND BENCHMARKS TRACK, 37., 2023. **Proceedings** [...]. Disponível em: https://arxiv.org/abs/2305.13117. Acesso em: 18 set. 2026.

TUKEY, John W. **Exploratory data analysis**. Reading: Addison-Wesley, 1977.

WANG, William Yang. Liar, liar pants on fire: a new benchmark dataset for fake news detection. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 55., 2017, Vancouver. **Proceedings** [...]. p. 422-426. Disponível em: https://aclanthology.org/P17-2067/. Acesso em: 18 set. 2026.

APÊNDICE A – NOTEBOOKS DA ANÁLISE EXPLORATÓRIA

Todos os números, quadros e figuras das seções 3 a 5 foram extraídos das saídas dos notebooks listados abaixo, executados no Google Colab. Os notebooks contêm o código, as tabelas completas e as interpretações de cada etapa.

Quadro 12 – Notebooks da análise exploratória

Arquivo	Conjunto	Partições	Células
EDA_AVERITEC_BR__f.ipynb	AVERITEC-BR	Treino e desenvolvimento	166
EDA_AVeriteC__f.ipynb	AVeriTeC	Treino e desenvolvimento	68
EDA_LIAR__f.ipynb	LIAR-BR	Treino, validação e teste	97

Fonte: elaborado pelo grupo (2026).